

# Analiza i przetwarzanie obrazów i wideo, wykład 7 (8)

## Detekcja obszarów zainteresowania. Ekstrakcja cech lokalnych

J. Sas

AI-Tech, 2022/2023

# Agenda:

- Klasyfikacja cech wykorzystywanych w APOW
- Detektory Moraveca i Harrisa
- Detektory SIFT i SURF
- Cechy tekstury obrazu
- Deskrytory obrazów wykorzystujące rozkłady cech lokalnych

**Ekstrakcja cech** stanowi syntezę danych wizualnych, mającą na celu wydobyć informacji istotnej dla użytkownika.

- Występuje w praktycznie każdej metodzie analizy obrazu.
- Stanowi kluczowy element metod analizy obrazu.
- Dostarcza podstawowych informacji do dalszego przetwarzania.
- Powinna być **dostosowana** do rozwiązywanego problemu.
- Jest wykonywana dla określonego **regionu zainteresowania**.
- Wielka różnorodność cech i metod ekstrakcji opisanych w literaturze.

# Podział cech ze względu obszar ekstrakcji

- **Globalne:**

- jeden obszar zainteresowania obejmujący cały obraz.
- charakteryzują cały obraz, pomijając szczegóły.

- **Semi-globalne, semi-lokalne:**

- reprezentują duże i istotne części obrazu.
- zazwyczaj jest kilka do kilkunastu regionów.
- mogą odzwierciedlać obiekty znajdujące się na obrazie.
- mogą dzielić obraz w sztywny, ustalony sposób.

- ...

# Podział cech ze względu obszar ekstrakcji

- **Globalne:** ...
- **Semi-globalne, semi-lokalne:** ...
- **Lokalne:**
  - reprezentują własności niewielkich fragmentów obrazu.
  - cecha opisuje własności **obszaru zainteresowania** - (ang. *Region of Interest* - *Roi*) wokół **punktu zainteresowania/kluczowego** (ang. *Keypoint* lub *Point of Interest* - *Pol*).
  - można zastosować do detekcji obiektów w obrazie - znalezione punkty kluczowe składają się na jeden obiekt (jak je łączyć?).
  - ROI mogą się wzajemnie nakładać (nie są rozłączne).
  - dla uproszczenia analizy Roi mogą być aproksymowane określoną figurą geometryczną (np. elipsą).
  - duża liczba Pol/Roi w obrazie - rzędu kilkaset do kilku tysięcy.
  - wyznaczanie Pol i otaczających je Roi jest formą segmentacji obrazu - segment: otoczenie punktu kluczowego, jak np. w MSER.

## Niezmienniczość

**Niezmienniczość** – stałość cechy przy określonych przekształceniach obrazu.

- Niezmienniczość cech znacznie ułatwia dalszą analizę,
- W różnych zadaniach oczekujemy niezmienności względem różnych czynników,
- Wybór cech należy oprzeć o ich niezmienniczość.
- Przykłady niezmienniczości względem typowych czynników:
  - od zmiany jasności,
  - od zmiany natężenia kolorów,
  - od zmiany warunków zewnętrznego oświetlenia,
  - od obrotu,
  - od przesunięcia,
  - od skalowania,
  - od przekształcenia afinicznego (obroty, przesunięcia i skalowania).

# Cechy – niezmienniczość



## Dlaczego narożniki są ważne jako punkty kluczowe?

- narożniki i T-złączenia (T-junctions) często są charakterystycznymi punktami wyznaczającymi kształty
- lepiej identyfikują kształty niż krawędzie
- jest ich znacznie mniej niż punktów na krawędziach
- pozostają w zbliżonych relacjach geometrycznych po transformacjach geometrycznych obrazu:
  - np. przy zmianie warunków obserwacji (rzutowania) sceny na powierzchnię obrazu



# Detektor narożników Moraveca

## Zasada:

- Rozważamy niewielki fragment (np. kołowy) obrazu
- Wyliczamy w nim średnią jasność (lub wartość innego atrybutu)
- W przypadku obszaru (prawie) jednorodnego niewielka zmiana położenia fragmentu nie prowadzi do istotnych zmian wartości średniej, niezależnie od kierunku zmiany położenia,
- W przypadku krawędzi przesunięcie wzdłuż krawędzi nie powoduje zmiany, przesunięcie prostopadłe do krawędzi powoduje największą zmianę,
- W przypadku narożnika - nie ma takiego kierunku przesunięcia, który nie powodowałby znacznych zmian wartości średniej, tzn. przesunięcie w dowolnym kierunku daje duże zmiany średniej.



## Zmiana przy przesunięciu fragmentu:

$$E(x, y, \Delta_x, \Delta_y) = \sum_{(x', y') \in W(x, y)} w(x', y') (I(x' + \Delta_x, y' + \Delta_y) - I(x', y'))^2 \quad (1)$$

- $w(x', y')$  - wektor wagi dla pozycji  $(x', y') \in W$
- $(\Delta_x, \Delta_y)$  - wektor "próbego" przesunięcia okna.
- kierunki próbne:  $(\Delta_x, \Delta_y) = (1, 0), (0, 1), (1, 1), (1, -1)$
- $Q(x, y) = \min\{E(x, y, 1, 0), E(x, y, 0, 1), E(x, y, 1, 1), E(x, y, 1, -1)\}$ 
  - im  $Q(x, y)$  większe tym bardziej prawdopodobne wystąpienie narożnika (min bo dla narożnika zmiany w każdym z kierunków duże)
- jako punkt narożnikowy (kluczowy) przyjmujemy wystąpienie lokalnego maximum  $Q(x, y)$  o wartości powyżej ustalonego progu

## Wady detektora Moraveca:

- badamy tylko cztery kierunki
- podatność na szumy
- lokalne maksima  $E$  mogą być nieprecyzyjne (fałszywe narożniki przy maksimach nieznacznie różniących się od otoczenia)

# Detektor narożników Harrisa

## Wady detektora Moraveca:

- badamy tylko cztery kierunki
- podatność na szумы
- lokalne maksima  $E$  mogą być nieprecyzyjne (fałszywe narożniki przy maksimach nieznacznie różniących się od otoczenia)

## Rozwinięcie i udoskonalenie detektora Moraveca:

- zmniejszenie podatności na szумы przez wstępne filtrowanie wygładzające (Gauss)
- brak ograniczenia rozważanych kierunków przesunięcia okna
- inna zasada ostatecznej decyzji o wykryciu narożnika

# Detektor narożników Harrisa

- Różnica średniej jasności przy przesunięciu o wektor  $(\Delta_x, \Delta_y)$ ,  $W$  - obszar wokoło  $(x, y)$ ;  $w(x', y')$  - waga punktu w średniej ważonej:

$$E(x, y, \Delta_x, \Delta_y) = \sum_{(x', y') \in W(x, y)} w(x', y') (I(x' + \Delta_x, y' + \Delta_y) - I(x', y'))^2$$

- Wyrażamy za pomocą gradientu  $(I_x, I_y)$ :

$$I(x' + \Delta_x, y' + \Delta_y) - I(x', y') = [I_x(x', y'), I_y(x', y')] [\Delta_x, \Delta_y]^T$$

- Sumę dla dowolnego kierunku przesunięcia testowego  $(\Delta_x, \Delta_y)$  wyrażamy za pomocą macierzy sumy iloczynów pochodnych cząstkowych  $Q(x, y)$

$$E(x, y, \Delta_x, \Delta_y) = \sum_{(x', y') \in W(x, y)} w(u, v) ([I_x(x', y'), I_y(x', y')] [\Delta_x, \Delta_y]^T)^2 =$$

$$[\Delta_x, \Delta_y] Q(x, y) [\Delta_x, \Delta_y]^T$$

# Detektor narożników Harrisa

- Różnica średniej jasności przy przesunięciu o wektor  $(\Delta_x, \Delta_y)$ ,  $W$  - obszar wokoło  $(x, y)$ ;  $w(x', y')$  - waga punktu w średniej ważonej:

$$E(x, y, \Delta_x, \Delta_y) = \sum_{(x', y') \in W(x, y)} w(x', y') (I(x' + \Delta_x, y' + \Delta_y) - I(x', y'))^2$$

- Wyrażamy za pomocą gradientu  $(I_x, I_y)$ :

$$I(x' + \Delta_x, y' + \Delta_y) - I(x', y') = [I_x(x', y'), I_y(x', y')] [\Delta_x, \Delta_y]^T$$

- Sumę dla dowolnego kierunku przesunięcia testowego  $(\Delta_x, \Delta_y)$  wyrażamy za pomocą macierzy sumy iloczynów pochodnych cząstkowych  $Q(x, y)$

$$E(x, y, \Delta_x, \Delta_y) = \sum_{(x', y') \in W(x, y)} w(u, v) ([I_x(x', y'), I_y(x', y')] [\Delta_x, \Delta_y]^T)^2 =$$

$$[\Delta_x, \Delta_y] Q(x, y) [\Delta_x, \Delta_y]^T$$

# Detektor narożników Harrisa

- Różnica średniej jasności przy przesunięciu o wektor  $(\Delta_x, \Delta_y)$ ,  $W$  - obszar wokół  $(x, y)$ ;  $w(x', y')$  - waga punktu w średniej ważonej:

$$E(x, y, \Delta_x, \Delta_y) = \sum_{(x', y') \in W(x, y)} w(x', y') (I(x' + \Delta_x, y' + \Delta_y) - I(x', y'))^2$$

- Wyrażamy za pomocą gradientu  $(I_x, I_y)$ :

$$I(x' + \Delta_x, y' + \Delta_y) - I(x', y') = [I_x(x', y'), I_y(x', y')] [\Delta_x, \Delta_y]^T$$

- Sumę dla dowolnego kierunku przesunięcia testowego  $(\Delta_x, \Delta_y)$  wyrażamy za pomocą macierzy sumy iloczynów pochodnych cząstkowych  $Q(x, y)$

$$E(x, y, \Delta_x, \Delta_y) = \sum_{(x', y') \in W(x, y)} w(u, v) ([I_x(x', y'), I_y(x', y')] [\Delta_x, \Delta_y]^T)^2 =$$

$$[\Delta_x, \Delta_y] Q(x, y) [\Delta_x, \Delta_y]^T$$

Macierz  $Q$  (dla uproszczenia pominięto wagi  $w(x', y')$ ):

$$Q(x, y) = \begin{bmatrix} a & b \\ b & c \end{bmatrix} = \begin{bmatrix} \sum_W I_x(x, y)^2 & \sum_W I_x(x, y) I_y(x, y) \\ \sum_W I_x(x, y) I_y(x, y) & \sum_W I_y(x, y)^2 \end{bmatrix}$$

- $E(x, y, \delta) = \delta Q(x, y) \delta^T$ ;  $\delta = (\Delta_x, \Delta_y)$  dla ustalonego  $(x, y)$  wyraża jak zmienia się średnia jasność w oknie  $W$  przy przesunięciu o  $\delta$ .
- Szukamy takich  $(x, y)$  aby zmiany przy niewielkim przesunięciu w dowolnym kierunku były duże.
- Równanie  $E(\delta) = \delta Q(x, y) \delta^T = 1$ ;  $\delta = (\Delta_x, \Delta_y)$  na płaszczyźnie kierunków  $\delta$  opisuje elipsę  $a\Delta_x^2 + 2b\Delta_x\Delta_y + c\Delta_y^2 = 1$  gdzie wektory własne macierzy  $Q$  są kierunkami osi a wartości własne  $\lambda_i$  są odwrotnościami długości osi:

$$d_i = 1/\sqrt{\lambda_i}; i = 1, 2$$



# Detektor narożników Harrisa

Macierz  $Q$  (dla uproszczenia pominięto wagi  $w(x', y')$ ):

$$Q(x, y) = \begin{bmatrix} a & b \\ b & c \end{bmatrix} = \begin{bmatrix} \sum_W I_x(x, y)^2 & \sum_W I_x(x, y) I_y(x, y) \\ \sum_W I_x(x, y) I_y(x, y) & \sum_W I_y(x, y)^2 \end{bmatrix}$$

- Równanie  $E(\delta) = \delta Q(x, y) \delta^T = 1$ ;  $\delta = (\Delta_x, \Delta_y)$  na płaszczyźnie kierunków  $\delta$  opisuje elipsę  $a\Delta_x^2 + 2b\Delta_x\Delta_y + c\Delta_y^2 = 1$  gdzie wektory własne macierzy  $Q$  są kierunkami osi a wartości własne są odwrotnościami długości osi.
- Jeśli  $\delta$  będzie wektorem jednostkowym to mała wartość  $E(\delta)$  oznacza, że aby dojść do krawędzi elipsy należy przesunąć się znacznie (brak zmian w tym kierunku) - tak będzie jeśli idziemy wzdłuż długiej osi elipsy (mała wartość własna)
- Jeśli  $\delta$  będzie wektorem jednostkowym to duża wartość  $E(\delta)$  oznacza, że aby dojść do krawędzi elipsy należy przesunąć się nieznacznie (szybkie zmiany w tym kierunku) - tak będzie jeśli idziemy wzdłuż krótkiej osi elipsy (duża wartość własna)


# Detektor narożników Harrisa

Macierz  $Q$ :

$$Q(x, y) = \begin{bmatrix} a & b \\ b & c \end{bmatrix} = \begin{bmatrix} \sum_W I_x(x_y)^2 & \sum_W I_x(x_y) I_y(x, y) \\ \sum_W I_x(x_y) I_y(x, y) & \sum_W I_y(x, y)^2 \end{bmatrix}$$

- Mamy punkt narożnikowy jeśli wartości różnicy  $E(\delta)$  przy dowolnym kierunku  $\delta = (\Delta_x, \Delta_y)$  są duże
- Jeśli jedna z osi elipsy jest długa (mała wartość własna) to duże zmiany położenia w tym kierunku dają małe zmiany wartości  $c$
- Jeśli obie osie elipsy są krótkie (duże wartości własne) to nawet małe zmiany położenia w tym kierunku dają duże zmiany  $c$  - PUNKT NAROŻNIKOWY
- Jeśli jedna z osi elipsy jest długa (mała wartość własna) a druga krótka (duża wartość własna) to mamy do czynienia z krawędzią
- Jeśli obie osie elipsy są długie (małe wartości własne) to mamy do czynienia z obszarem jednorodnym lub gładko cieniowanym

# Detektor narożników Harrisa



Macierz  $Q$ :

$$Q(x, y) = \begin{bmatrix} a & b \\ b & c \end{bmatrix} = \begin{bmatrix} \sum_W I_x(x_y)^2 & \sum_W I_x(x_y)I_y(x, y) \\ \sum_W I_x(x_y)I_y(x, y) & \sum_W I_y(x, y)^2 \end{bmatrix}$$

- Można wykazać, że obie wartości własne są duże, gdy następująca funkcja osiąga dużą wartość:

$$R(x, y) = \det(Q(x, y)) - \alpha \text{trace}(Q(x, y))^2 \quad (2)$$

$$R(x, y) = \lambda_1 \lambda_2 - \alpha(\lambda_1 + \lambda_2)^2 \quad (3)$$

gdzie  $\alpha$  empirycznie ustalono na około (0.4-0.8)

- Ostatecznie uznajemy że występuje punkt narożnikowy tam gdzie  $R(x, y)$  osiąga lokalne maksimum

# Zastosowane odmiany detektorów:

- Harris-Affine - podobnie jak w detektorze Harrisa, ale:
  - wyznaczone są maksima w przestrzeni skal oraz
  - odpowiedź detektora maksymalizuje się względem obrotu i nierównomiernego skalowania wzdłuż osi.

Szczegóły w: K. Mikolajczyk, C. Schmid: Scale & Affine Invariant Interest Point Detectors. 2004.

- Hessian-Affine - podobnie jak w detektorze Harris-Affine, ale ...
  - zamiast macierzy pierwszych pochodnych wykorzystuje się macierz drugich pochodnych (hesjan) -  $I_{xx}$ ,  $I_{xy}$ ,  $I_{yx}$ ,  $I_{yy}$  oraz jego wyznacznik


Szczegóły w: K. Mikolajczyk: Detection of local features invariant to affine transformations, PhD thesis, 2002

([http://perception.inrialpes.fr/Publications/2002/Mik02/Mikolajczyk\\_these2002.pdf](http://perception.inrialpes.fr/Publications/2002/Mik02/Mikolajczyk_these2002.pdf))


# Punkty kluczowe – przykład




(a) obraz



(b) Harris-Affine



(c) Hessian-Affine



(d) MSER

# Punkty kluczowe – przykład



# Punkty kluczowe – po co to jest?

Do czego mogą posłużyć punkty kluczowe:

- identyfikowanie rejonów zainteresowania
- rozpoznawanie obiektów
- znajdowanie obszarów podobnych
- śledzenie obiektów/modelowanie ruchu (→ np. SLAM)
- rekonstrukcja 3D (np. Structure from motion)
- ...

Co jest potrzebne a czego punkty kluczowe same w sobie nie mają?



# Punkty kluczowe – po co to jest?

Do czego mogą posłużyć punkty kluczowe:

- identyfikowanie rejonów zainteresowania
- rozpoznawanie obiektów
- znajdowanie obszarów podobnych
- śledzenie obiektów/modelowanie ruchu (→ np. SLAM)
- rekonstrukcja 3D (np. Structure from motion)
- ...

Co jest potrzebne a czego punkty kluczowe same w sobie nie mają?

## Cechy:

- Metoda znajdowania punktów kluczowych i wyznaczania ich **deskryptorów** (lokalnych wektorów cech)
- Punkty zainteresowania mają cechy narożników
- Wymagana niezmienniczość względem wielkości obrazu (skali) i obrotów
- Niezmienniczość względem przesunięcia uzyskiwana z zasady (obliczenia dla otoczenia znalezionej punktu kluczowego)

# SIFT - Scale Invariant Feature Transform

## Etapy:

- Konstrukcja przestrzeni skal (uniezależnienie od wielkości detalu w obrazie)
- Wyznaczanie różnic w przestrzeni skal (DoG - *Difference of Gaussians*)
- Znajdowanie punktów kluczowych (ekstrema w trójwymiarowej przestrzeni DoG) - z aproksymacją dla dokładniejszej lokalizacji w obrazie o pierwotnej rozdzielczości przez rozwinięcie w szereg Taylora
- Odrzucanie punktów o niskim kontraście (pozostają tylko te o wysokich wartościach DoG oraz wysokich obydwu wartościach własnych macierzy pochodnych - jak w detektorze Harrisa)
- Uniezależnienie od obrotu - wyznaczenie kierunku dominującego gradientu poprzez budowę histogramu kierunków gradientów w otoczeniu punktu kluczowego,
  - ewentualne zwielokrotnienie punktu jeśli istnieje więcej niż jedno ewidentne maksimum - z jednego punktu kluczowego generujemy kilka deskryptorów

# SIFT - Scale Invariant Feature Transform

## Etapy:

- Konstrukcja przestrzeni skal (uniezależnienie od wielkości detalu w obrazie)
- Wyznaczanie różnic w przestrzeni skal (DoG - *Difference of Gaussians*)
- Znajdowanie punktów kluczowych (ekstrema w trójwymiarowej przestrzeni DoG) - z aproksymacją dla dokładniejszej lokalizacji w obrazie o pierwotnej rozdzielczości przez rozwinięcie w szereg Taylora
- Odrzucanie punktów o niskim kontraście (pozostają tylko te o wysokich wartościach DoG oraz wysokich obydwu wartościach własnych macierzy pochodnych - jak w detektorze Harrisa)
- Uniezależnienie od obrotu - wyznaczenie kierunku dominującego gradientu poprzez budowę histogramu kierunków gradientów w otoczeniu punktu kluczowego,
  - ewentualne zwielokrotnienie punktu jeśli istnieje więcej niż jedno ewidentne maksimum - z jednego punktu kluczowego generujemy kilka deskryptorów

# SIFT - Scale Invariant Feature Transform

## Etapy:

- Konstrukcja przestrzeni skal (uniezależnienie od wielkości detalu w obrazie)
- Wyznaczanie różnic w przestrzeni skal (DoG - *Difference of Gaussians*)
- Znajdowanie punktów kluczowych (ekstrema w trójwymiarowej przestrzeni DoG) - z aproksymacją dla dokładniejszej lokalizacji w obrazie o pierwotnej rozdzielczości przez rozwinięcie w szereg Taylora
- Odrzucanie punktów o niskim kontraście (pozostają tylko te o wysokich wartościach DoG oraz wysokich obydwu wartościach własnych macierzy pochodnych - jak w detektorze Harrisa)
- Uniezależnienie od obrotu - wyznaczenie kierunku dominującego gradientu poprzez budowę histogramu kierunków gradientów w otoczeniu punktu kluczowego,
  - ewentualne zwielokrotnienie punktu jeśli istnieje więcej niż jedno ewidentne maksimum - z jednego punktu kluczowego generujemy kilka deskryptorów

# SIFT - Scale Invariant Feature Transform

## Etapy:

- Konstrukcja przestrzeni skal (uniezależnienie od wielkości detalu w obrazie)
- Wyznaczanie różnic w przestrzeni skal (DoG - *Difference of Gaussians*)
- Znajdowanie punktów kluczowych (ekstrema w trójwymiarowej przestrzeni DoG) - z aproksymacją dla dokładniejszej lokalizacji w obrazie o pierwotnej rozdzielczości przez rozwinięcie w szereg Taylora
- Odrzucanie punktów o niskim kontraście (pozostają tylko te o wysokich wartościach DoG oraz wysokich obydwu wartościach własnych macierzy pochodnych - jak w detektorze Harrisa)
- Uniezależnienie od obrotu - wyznaczenie kierunku dominującego gradientu poprzez budowę histogramu kierunków gradientów w otoczeniu punktu kluczowego,
  - ewentualne zwielokrotnienie punktu jeśli istnieje więcej niż jedno ewidentne maksimum - z jednego punktu kluczowego generujemy kilka deskryptorów

# SIFT - Scale Invariant Feature Transform


## Etapy:

- Konstrukcja przestrzeni skal (uniezależnienie od wielkości detalu w obrazie)
- Wyznaczanie różnic w przestrzeni skal (DoG - *Difference of Gaussians*)
- Znajdowanie punktów kluczowych (ekstrema w trójwymiarowej przestrzeni DoG) - z aproksymacją dla dokładniejszej lokalizacji w obrazie o pierwotnej rozdzielczości przez rozwinięcie w szereg Taylora
- Odrzucanie punktów o niskim kontraście (pozostają tylko te o wysokich wartościach DoG oraz wysokich obydwu wartościach własnych macierzy pochodnych - jak w detektorze Harrisa)
- Uniezależnienie od obrotu - wyznaczenie kierunku dominującego gradientu poprzez budowę histogramu kierunków gradientów w otoczeniu punktu kluczowego,
  - ewentualne zwielokrotnienie punktu jeśli istnieje więcej niż jedno ewidentne maksimum - z jednego punktu kluczowego generujemy kilka deskryptorów

# SIFT - Budowa przestrzeni skal i DoG

- Dążymy do wykrycia krawędzi filtrem Laplace'a ale z uniknięciem efektu szumu - stosujemy DoG
- Potrzebujemy wariantów obrazów o różnym stopniu rozmycia - skala rozmycia w bardzo dużym zakresie
- Stosowanie filtrów konwolucyjnych o dużych rozmiarach (duże  $\sigma$ ) kosztowne obliczeniowo
- Zamiast filtrowania filtrami o dużej masce - zastosować zmniejszanie obrazu przez uśrednianie pikseli (operacja mało kosztowna)

**Rysunek 1:** Wyznaczanie DoG w przestrzeni skal






# SIFT - Wyznaczanie kandydujących punktów kluczowych

- Odejmujemy od siebie sąsiednie obrazy w ciągu skal - otrzymujemy DoG dla różnych skal
- W/w operacja odpowiada detekcji krawędzi
- Znajdujemy maksima w 3D
- Dla dokładniejszej lokalizacji punktu (ze względu na zastosowaną *piramidę obrazów*) "uciągłamy" funkcję jasności przez aproksymację z szeregu Tylora


**Rysunek 2:** Wyznaczanie 3D maksimów



# SIFT - Wyznaczanie kandydujących punktów kluczowych

- ...
- W praktyce: tak otrzymanych punktów kandydujących wciąż za dużo - stosujemy do otrzymanych kandydatów detektor narożników Harrisa
- Punkty, które spełniają kryterium narożnika detektora Harrisa uznajemy za poszukiwane punkty kluczowe


**Rysunek 3:** Wyznaczanie 3D maksimów



## SIFT - niezmienniczość względem obrotu

- W otoczeniu punktu kluczowego budujemy 8-binowy histogram gradientów
- Znajdujemy kierunek dominujący w histogramie gradientów (maksimum)
- Sektor odpowiadający maksimum uznajemy za kierunek dominujący
- Jeśli w zakresie 80% globalnego maksimum znajdują się inne lokalne maksima to punkt traktujemy jako wielokrotny - z wieloma kierunkami dominującymi
- Przy dalszym wyznaczaniu deskryptora obracamy lokalnie obraz o kąt dominujący

# SIFT - wyliczanie deskryptora



- Region zainteresowania - kwadrat  $16 \times 16$  otaczający punkt kluczowy
- Region zainteresowania podzielony na fragmenty (tutaj:  $16 \times 4 \times 4$ )
- W każdym subregionie  $4 \times 4$  budujemy 8-binowy histogram gradientów
- Siła krawędzi (w histogramie) dodatkowo ważona odległością od środka
- Wektor cech – złączenie otrzymanych znormalizowanych histogramów (normalizacja L1 do 1)
- Razem  $8 \times 16 = 128$  cech
- Dodatkowo współrzędne regionu zainteresowania.

Ciąg dalszy nastąpi!